

UNIVERSIDADE CATÓLICA DE PERNAMBUCO – UNICAP

PRÓ-REITORIA DE PESQUISA

JHON VICTOR RAMOS MARTINS

**DETECÇÃO DE FALHAS COM DADOS DE SENSORES INDUSTRIAIS
E VALIDAÇÃO EXPERIMENTAL**

RELATÓRIO PARCIAL DE INICIAÇÃO CIENTÍFICA

**RECIFE
2026**

JHON VICTOR RAMOS MARTINS

**DETECÇÃO DE FALHAS COM DADOS DE SENSORES INDUSTRIAIS
E VALIDAÇÃO EXPERIMENTAL**

Relatório Parcial apresentado à Pró-Reitoria de Pesquisa e Pós-Graduação da Universidade Católica de Pernambuco, como requisito integrante para avaliação do desempenho no Programa Institucional de Bolsas de Iniciação Científica (PIBIC/UNICAP), vigência 2025-2026.

Orientador: Prof. Dr. Wilmer Yecid Córdoba Camacho

**RECIFE
2026**

RESUMO

Este relatório exhibe as atividades desenvolvidas no primeiro semestre do projeto de iniciação científica focado na detecção de falhas em sistemas industriais. O objetivo central é o desenvolvimento de competências teóricas e práticas para a identificação de anomalias em sensores utilizando abordagens de aprendizado de máquina. No período relatado, realizou-se uma revisão sistemática da literatura sobre a taxonomia de anomalias e modelos de séries temporais. Na etapa prática, procedeu-se à análise exploratória dos dados de vibração do dataset *Case Western Reserve University* (CWRU). Os resultados preliminares, obtidos via cálculos de RMS e testes de estacionariedade (ADF), comprovaram uma distinção energética significativa entre rolamentos saudáveis e defeituosos, validando a adequação dos dados para a fase subsequente de treinamento de modelos preditivos.

Palavras-chave: Detecção de anomalias; Manutenção preditiva; Séries temporais; CWRU dataset.

ABSTRACT

This report presents the activities developed in the first semester of the scientific initiation project focused on fault detection in industrial systems. The central objective is the development of theoretical and practical skills for identifying anomalies in sensors using machine learning approaches. During the reported period, a systematic literature review on anomaly taxonomy and time series models was conducted. In the practical stage, an exploratory analysis of vibration data from the Case Western Reserve University (CWRU) dataset was performed. The preliminary results, obtained via RMS calculations and stationarity tests (ADF), confirmed a significant energy distinction between healthy and defective bearings, validating the suitability of the data for the subsequent phase of predictive model training.

Keywords: Anomaly detection; Predictive maintenance; Time series; CWRU dataset.

SUMÁRIO

1. INTRODUÇÃO	6
2. OBJETIVOS	6
2.1. OBJETIVO GERAL	6
2.2. OBJETIVOS ESPECÍFICOS.....	6
3. FUNDAMENTAÇÃO TEÓRICA	6
3.1. DETECÇÃO DE ANOMALIAS.....	7
3.2. SÉRIES TEMPORAIS E MANUTENÇÃO PREDITIVA	7
3.3. MODELOS COMPUTACIONAIS E ESTADO DA ARTE	8
4. METODOLOGIA.....	8
4.1. BASE DE DADOS (DATASET CWRU)	8
4.2. FERRAMENTAS COMPUTACIONAIS.....	8
5. ATIVIDADES REALIZADAS E RESULTADOS PRELIMINARES.....	9
5.1. ANÁLISE VISUAL NO DOMÍNIO DO TEMPO	9
5.2. ANÁLISE ESTATÍSTICA (RMS E ESTACIONARIEDADE)	10
6. CRONOGRAMA DAS PRÓXIMAS ETAPAS	11
REFERÊNCIAS	11

1. INTRODUÇÃO

A detecção de falhas em sistemas industriais tem sido um dos pilares da manutenção preditiva, especialmente em ambientes produtivos onde a confiabilidade de máquinas é crítica para evitar perdas financeiras, acidentes ou interrupções de processo. Com o avanço de sensores de baixo custo e microcontroladores como o Raspberry Pi, torna-se cada vez mais viável coletar dados em tempo real sobre variáveis como vibração, som, temperatura e corrente elétrica. Paralelamente, o campo da inteligência artificial tem desenvolvido modelos que detectam anomalias de forma cada vez mais precisa, porém muitas vezes sem considerar sua replicabilidade prática.

Este projeto justifica-se por três razões principais. Primeiro, promove a formação de recursos humanos capacitados em técnicas modernas de aprendizado de máquina e aquisição de dados em sistemas reais. Segundo, integra de maneira aplicada a teoria à prática, oferecendo uma experiência de validação experimental que vai além da simulação computacional. Terceiro, os conhecimentos gerados são diretamente aplicáveis na indústria 4.0, contribuindo para inovação tecnológica regional e nacional.

2. OBJETIVOS

2.1. OBJETIVO GERAL

Desenvolver competências teóricas e práticas na detecção de falhas em sistemas industriais a partir de sensores, combinando revisão bibliográfica, aplicação computacional e montagem experimental.

2.2. OBJETIVOS ESPECÍFICOS

- Levantar e classificar os principais modelos usados para detecção de falhas com dados de sensores.
- Implementar modelos como Isolation Forest, Random Forest, Autoencoders e CNNs em Python.

- Aplicar esses modelos em bases públicas (MIMII, CWRU, SECOM).
- Realizar montagem com Raspberry Pi e sensores simulando estados com falhas.
- Coletar e processar os dados reais para testar os modelos desenvolvidos.
- Produzir relatório técnico e/ou artigo sobre a experiência teórica e experimental.

3. FUNDAMENTAÇÃO TEÓRICA

A fundamentação teórica desse projeto baseia-se no ponto em comum entre a análise de séries temporais e a detecção de anomalias aplicadas ao contexto da indústria 4.0. Abaixo, vê-se os conceitos fundamentais que norteiam a pesquisa:

3.1. DETECÇÃO DE ANOMALIAS

A detecção de anomalias refere-se ao problema de encontrar padrões em dados que não estão em conformidade com o comportamento esperado. Segundo o *survey* seminal de Chandola et al. (2009), anomalias são padrões que se desviam significativamente do normal, levantando suspeitas de que foram gerados por um mecanismo diferente.

No contexto dessa pesquisa, as anomalias podem ser classificadas em três categorias principais:

3.1.1. **Anomalias de ponto:** Quando uma instância de dado é considerada anômala em relação ao restante.

3.1.2. **Anomalias contextuais:** Quando uma amostra individual só é anômala em um contexto específico.

- Um dado de uma temperatura de uma máquina. Em operação plena, aquela temperatura pode ser normal. Mas em repouso, tal valor configura uma anomalia.

3.1.3. **Anomalias coletivas:** Quando uma coleção de amostras relacionadas é anômala, embora seus valores individualmente não sejam.

- Uma coleção de dados que representa um desgaste gradual.

Sobre os modos de aprendizagem, esse projeto foca majoritariamente na abordagem **não supervisionada** e **semi-supervisionada**. Visto que, em ambientes industriais reais, a obtenção de dados rotulados de todas as falhas é inviável na maioria das vezes.

3.2. SÉRIES TEMPORAIS E MANUTENÇÃO PREDITIVA

Os dados oriundos de sensores industriais – como termopares – e dispostos sob uma ordem cronológica, são chamados de **séries temporais**. Para que sua análise seja frutífera, exige-se a compreensão de conceitos base, como:

- **Tendência:** A direção de **longo prazo** que os dados seguirão.
- **Sazonalidade:** Padrões que ocorrem em intervalos fixos.
 - Por exemplo: anualmente, na época do verão, a venda de alimentos gelados aumenta.
- **Ruído:** Variações aleatórias.
- **Estacionariedade:** Propriedade estatística fundamental onde a variância e a média mantêm-se constantes ao longo do tempo. Para diversos modelos de previsão e detecção, a verificação da estacionariedade – através de métodos como ADF (*Augmented Dickey-Fuller*) – é um pré-requisito.

A aplicação desses conceitos na **manutenção preditiva** tem como objetivo apontar falhas antes mesmo que elas ocorram, utilizando o histórico de dados para identificar desvios sutis no comportamento da máquina. Permitindo, por consequência, intervenções planejadas e a redução de custos por paradas não programadas.

3.3. MODELOS COMPUTACIONAIS E ESTADO DA ARTE

A literatura recente aponta para uma evolução dos modelos clássicos estatísticos – como o *ARIMA* – para metodologias que utilizam inteligência artificial. Técnicas de *Deep Learning*, como Redes Neurais Recorrentes (LSTMs/RNNs) e, recentemente, arquiteturas baseadas em *Transformers* (YI et al., 2024), têm demonstrado superioridade na

captura de complexas dependências temporais e relações não-lineares em dados multivariados.

4. METODOLOGIA

A metodologia utilizada nesse projeto possui uma abordagem experimental e quantitativa. Devido a natureza crítica dos dados industriais, optou-se por iniciar o desenvolvimento utilizando bases de dados de referência (padrão-ouro) antes da coleta de dados reais, garantindo, assim, a validação dos algoritmos em um ambiente controlado.

4.1. BASE DE DADOS (DATASET CWRU)

Para o desenvolvimento e testes dos modelo de detecção de anomalias utilizou-se o conjunto de dados *Case Western Reserve University (CWRU) Bearing Data Center*, que possui amplo reconhecimento na literatura como referência para diagnóstico de falhas em rolamentos.

Selecionou-se arquivos de dados com frequência de 12kHz. Coletados no acelerômetro da extremidade de acionamento (conhecido como *Drive End*). Para a análise preliminar, focou-se em dois cenários distintos para permitir uma comparação binária clara:

- **Baseline (cenário normal):** Arquivo 97.mat. Motor operando a aprox. 1797 rpm, carga 0 HP.
- **Cenário de falha:** Arquivo 105.mat. Falha artificialmente induzida no anel interno – *Inner Race* com diâmetro de 0.007 polegadas, sob mesma carga e rotação.

4.2. FERRAMENTAS COMPUTACIONAIS

Todo o processamento de dados foi realizado em linguagem Python (versão 3.12.12), utilizando o ambiente de desenvolvimento em nuvem *Google Colab*, que permite a execução de códigos e a visualização de dados de forma colaborativa e escalável.

As principais bibliotecas utilizadas foram:

- **SciPy:** Para o carregamento e manipulação dos arquivos brutos no formato .mat (Matlab).
- **NumPy:** Para operações matemáticas e cálculo de métricas estatísticas.
- **Matplotlib:** Para a visualização dos sinais no domínio do tempo.
- **Statsmodels:** Para a realização de testes estatísticos de estacionariedade.

5. ATIVIDADES REALIZADAS E RESULTADOS PRELIMINARES


Conforme cronograma, as atividades deste período focaram na revisão bibliográfica, estudo das ferramentas e na análise exploratória dos dados (AED). A AED é uma etapa crítica para compreender a natureza estocástica dos sinais antes da implementação de modelos de Machine Learning.

5.1. ANÁLISE VISUAL NO DOMÍNIO DO TEMPO

A primeira etapa consistiu na transformação dos sinais brutos de vibração em um gráfico. O objetivo foi verificar se o rolamento, quando falha, produz uma assinatura de sinal distinta da operação normal.

A figura 1 apresenta a comparação entre os primeiros 2000 pontos de dados de cada cenário.

Figura 1. Comparativo entre sinal de vibração normal (topo) e com falha no anel interno (fundo).



(Fonte: O autor, 2026)

Como mostra a Figura 1, o sinal apresenta uma amplitude baixa e constante, característico de um ruído operacional em estado normal. Ao passo que o sinal com falha no anel interno exibe picos de impacto (impulsos) periódicos e de alta amplitude, causados pelo contato dos elementos rolantes com a falha na pista. Essa distinção visual confirma a viabilidade de utilizar a amplitude do sinal como um dos preditores de anomalia.

5.2. ANÁLISE ESTATÍSTICA (RMS E ESTACIONARIEDADE)

Para transformar a diferença visual em dados quantitativos, calculou-se o RMS (*Root Mean Square*) que representa a **energia média do sinal**. Além disso, para verificar a estacionariedade das séries, o teste Augmented Dickey-Fuller (*ADF*) também foi aplicado.

A Tabela 1 resume os resultados obtidos:

Tabela 1 – Resultados estatísticos de RMS e Teste ADF

Condição	Valor RMS (Energia)	Resultado Teste ADF (p-valor)	Conclusão
Baseline (Normal)	0.0738	0.0000	Série estacionária
Com falha (Inner Race)	0.2915	0.0000	Série estacionária

(Fonte: O autor, 2026)

Como é possível ver na tabela, o valor RMS (a energia) sofre um **aumento de 295%** em comparação com o sinal normal. Além disso, como o p valor obteve um resultado muito abaixo de 0.05, pode-se rejeitar a hipótese nula.

Isso é um importante achado para as próximas etapas, pois indica que as propriedades estatísticas (variância e média) são estáveis ao longo do tempo, o que torna esses dados adequados para treinar os modelos de reconstrução e previsão planejados para as próximas etapas.

6. CRONOGRAMA DAS PRÓXIMAS ETAPAS

Para o restante do PIBIC (2025-2026), o planejado é a evolução da análise exploratória para a aplicação de modelos inteligentes. O cronograma previsto é:

- **Fevereiro – Março/2026:** Finalização da análise exploratória multivariada e início da implementação do modelo *Isolation Forest*.
- **Abril – Maio/2026:** Treinamento e validação de modelos de *Deep Learning* (Autoencoders e LSTMs) utilizando o dataset CWRU.
- **Junho/2026:** Comparação de métricas de desempenho (RMSE, F1-Score, Acurácia) e compilação dos resultados finais.
- **Julho/2026:** Escrita do relatório final e submissão do artigo científico com os resultados obtidos.

REFERÊNCIAS

CASE WESTERN RESERVE UNIVERSITY. **Bearing Data Center Seeded Fault Test Data**. Cleveland, [20--]. Disponível em:

<https://engineering.case.edu/bearingdatacenter/>. Acesso em: 15 fev. 2026.

CHANDOLA, V.; BANERJEE, A.; KUMAR, V. **Anomaly detection**: a survey. ACM Computing Surveys, v. 41, n. 3, p. 1-72, set. 2009.

YI, S. et al. **Anomaly detection for asynchronous multivariate time series of nuclear power plants using a temporal-spatial transformer**. Sensors, v. 24, n. 9, p. 2845, 2024. DOI: <https://doi.org/10.3390/s24092845>. Disponível em: <https://www.mdpi.com/1424-8220/24/9/2845>. Acesso em: 15 fev. 2026.